

# Universidad de Alcalá

## Escuela Politécnica Superior

**Grado en Ingeniería Informática**

### **Trabajo Fin de Grado**

Estudio de técnicas de visión e inteligencia artificial aplicadas a un caso práctico

**Autor:** Pablo García García

**Tutor:** Adrián Domínguez Díaz

2024



**UNIVERSIDAD DE ALCALÁ**  
**ESCUELA POLITÉCNICA SUPERIOR**

**Grado en Ingeniería Informática**

**Trabajo Fin de grado**

**Estudio de técnicas de visión e inteligencia artificial aplicadas a  
un caso práctico**

Autor: Pablo García García

Tutor: Adrián Domínguez Díaz

**Tribunal:**

**Presidente:**

**Vocal 1º:**

**Vocal 2º:**

Fecha de depósito:



*“Computer Science is no more about computers than astronomy is about telescopes.”*  
Edsger W. Dijkstra



# Resumen

Palabras clave:





# Abstract

**Keywords:**



# Índice general

<b>Resumen</b>	<b>7</b>
<b>Abstract</b>	<b>9</b>
<b>1. Introducción</b>	<b>13</b>
<b>2. Fundamentos de la Inteligencia Artificial y sus herramientas</b>	<b>15</b>
2.1. Breve historia de la Inteligencia Artificial . . . . .	15
2.2. ¿Qué es un modelo? . . . . .	15
2.3. Tipos de aprendizaje y problemas . . . . .	15
2.4. Convolución y correlación cruzada . . . . .	16
<b>3. Aprendizaje automático</b>	<b>20</b>
3.1. Perceptrón . . . . .	20
<b>Bibliografía</b>	<b>25</b>

# Índice de figuras

2.1. Detección de bordes aplicando los kernel Sobel . . . . .	17
3.1. Arquitectura de un perceptrón . . . . .	20
3.2. Puntos etiquetados en $\mathbb{R}^2$ . . . . .	21
3.3. Puntos separados en $\mathbb{R}^2$ . . . . .	22
3.4. Valores de $x \oplus y$ en $\mathbb{R}^2$ . . . . .	22

## Capítulo 1

# Introducción



## Capítulo 2

# Fundamentos de la Inteligencia Artificial y sus herramientas

En este capítulo se abordará una breve introducción al campo de la Inteligencia Artificial, comenzando desde su historia a lo largo del tiempo para contextualizar, pasando por entender los fundamentos de lo que busca lograr, y comentando alguna herramienta matemática que será de utilidad y que en ciertos casos causa confusiones.

### 2.1. Breve historia de la Inteligencia Artificial

### 2.2. ¿Qué es un modelo?

### 2.3. Tipos de aprendizaje y problemas

Una vez entendida cuál es la idea de un modelo, es momento de discutir cómo se hace posible que este desempeñe correctamente su tarea. Esto se logra mediante un algoritmo de aprendizaje o entrenamiento que ajusta de manera óptima los parámetros del modelo. Normalmente se dispone de dos tipos de aprendizaje, **aprendizaje supervisado** y **aprendizaje no supervisado**[1].

En los algoritmos de aprendizaje supervisados, se dispone de un conjunto de datos o *dataset*, que contiene los valores de salida deseados para diferentes valores de entrada, normalmente recogiendo situaciones del pasado para poder extrapolar este conocimiento a situaciones del futuro. Los principales problemas que utilizan algoritmos de aprendizaje supervisado son los problemas de clasificación y de regresión. En los **problemas de clasificación**, se dispone de una serie de clases  $C_1, C_2, \dots, C_n$ , y para una serie de valores de entrada  $x_1, x_2, \dots, x_m$ , debe decidirse a qué clase pertenece dicha entrada. Un ejemplo sería decidir si un paciente va a sufrir un cierto tipo de cáncer dada su edad, peso, y otras constantes vitales. Algunos de los modelos más populares para llevar a cabo este tipo de tareas son árboles de decisión, máquinas de soporte vectorial, Naïve Bayes,  $k$ -vecinos, y redes neuronales; siendo estas últimas objeto de estudio en este trabajo. Otro tipo de problema popular a la hora de disponer de datos etiquetados, son los **problemas de regresión**, que se diferencia principalmente de la clasificación en que en este caso, los valores no son clases (valores discretos) sino valores continuos. Para resolver este tipo de problemas se suelen utilizar regresiones lineales y no lineales (exponencial, polinómica, etc). Un ejemplo de un problema de regresión sería predecir las horas que dormirá una persona dada su edad, horas trabajadas en el día, horas de recreo en el día, etc.

Por otro lado, los algoritmos de aprendizaje no supervisado no reciben los valores de salida esperados para una cierta observación (justo al contrario que en el caso supervisado), pues será trabajo del algoritmo encontrar relaciones y patrones entre los datos proporcionados. En este tipo de aprendizaje también se trata el problema de clasificación, sin embargo, es más común llamarlo **clustering** o **segmentación**, pues

a priori no se conoce el número de clases y cuáles son, es el algoritmo el que deberá encontrar relaciones entre los datos para determinar esto. Algoritmos populares para realizar esta tarea son  $k$ -medias (y su variante  $k$ -medianas), clusterización jerárquica aglomerativa, modelos de mixtura gaussianos, y DBSCAN. Un ejemplo sencillo de este problema es detectar las diferentes regiones y objetos representados en una imagen, pues inicialmente no se conoce el número de regiones u objetos, y deben detectarse todas, asignando cada píxel de la imagen a cada una de ellas.

## 2.4. Convolución y correlación cruzada

Una de las operaciones matemáticas más conocidas y que es más usada al trabajar con señales e imágenes es la llamada convolución, denotada por  $*$ , y dadas las funciones  $f(t)$  y  $g(t)$ , su convolución se define de la siguiente manera.

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau) d\tau$$

En este caso se está asumiendo que el dominio de  $f(\tau)g(t - \tau)$  es  $\mathbb{R}$ , lo que permite integrar sobre todo  $\mathbb{R}$ , de lo contrario, se modifica la definición para integrar solo sobre un intervalo  $[a, b]$ . En general, esta operación crea una nueva función a partir de otras dos, que indica cómo interactúan entre sí, y que permite aplicar filtros a señales e imágenes. Como se acaba de comentar para el caso de las imágenes, se puede tratar con señales que no dependan únicamente de una variable, pues estas se representan como una función de dos variables  $f(u, v)$ . En este caso, la convolución queda definida de la siguiente manera.

$$(f * g)(u, v) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(\xi, \eta)g(u - \xi, v - \eta) d\xi d\eta$$

Partiendo de la primera definición mostrada, se pueden demostrar algunas propiedades útiles que cumple la convolución[2]:

- Conmutativa:  $f * g = g * f$
- Asociativa:  $f * (g * h) = (f * g) * h$
- Distributiva:  $f * (g + h) = (f * g) + (f * h)$
- Derivada:  $\frac{d}{dt}(f * g) = \frac{df}{dt} * g = \frac{dg}{dt} * f$
- Relación con las transformadas de Laplace y Fourier:  $\mathcal{L}\{f * g\} = \mathcal{L}\{f\} \cdot \mathcal{L}\{g\}$ , o lo que suele ser más útil,  $f * g = \mathcal{L}^{-1}\{\mathcal{L}\{f\} \cdot \mathcal{L}\{g\}\}$ , de forma que se puede calcular la convolución en tiempo  $\mathcal{O}(n \log(n))$  con el algoritmo FFT[3].

Si bien en las definiciones previas se ha tomado la integral y tanto  $\mathbb{R}$  como  $\mathbb{R}^2$  como dominios continuos sobre los que calcular la convolución, no se debe olvidar que las imágenes no dejan de ser matrices o funciones de dos variables con un dominio discreto, por lo que se debe presentar una definición adecuada a este caso[4].

$$(f * g)(u, v) = \sum_{i=-k}^k \sum_{j=-k}^k g(i, j)f(u - i, v - j)$$

En la expresión anterior, a la función  $g(u, v)$  se le llama filtro o *kernel* de convolución. A continuación se muestra un ejemplo de cómo calcular una convolución.



$$\begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ 5 & 6 & 7 & 8 & 9 \\ 9 & 8 & 7 & 6 & 5 \\ 5 & 4 & 3 & 2 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 14 & 15 & 16 \\ 16 & 15 & 14 \\ 16 & 15 & 14 \end{pmatrix}$$

$$\begin{aligned}
1 \cdot 1 + 2 \cdot 0 + 3 \cdot 0 + 5 \cdot 0 + 6 \cdot 1 + 7 \cdot 0 + 9 \cdot 0 + 8 \cdot 0 + 7 \cdot 1 &= 14 \\
2 \cdot 1 + 3 \cdot 0 + 4 \cdot 0 + 6 \cdot 0 + 7 \cdot 1 + 8 \cdot 0 + 8 \cdot 0 + 7 \cdot 0 + 6 \cdot 1 &= 15 \\
&\vdots \\
7 \cdot 1 + 6 \cdot 0 + 5 \cdot 0 + 3 \cdot 0 + 2 \cdot 1 + 1 \cdot 0 + 3 \cdot 0 + 4 \cdot 0 + 5 \cdot 1 &= 14
\end{aligned}$$

Aplicando diferentes kernels de convolución a una imagen se pueden extraer diferentes tipos de características de una imagen, como por ejemplo bordes. El filtro Sobel es capaz de hacer esto con los kernels que se muestran a continuación, pues se comportan como aproximaciones de las derivadas parciales de la imagen en un punto teniendo en cuenta los píxeles cercanos[5].

$$G_u = \frac{\partial f(u, v)}{\partial u} \approx \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix} \qquad G_v = \frac{\partial f(u, v)}{\partial v} \approx \begin{pmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}$$




Figura 2.1: Detección de bordes aplicando los kernel Sobel

A continuación se va a calcular la convolución de la matriz del ejemplo anterior con  $G_u$ . Para comprobar los cálculos, se puede realizar esto con la función `convn` de MATLAB. Al realizar los cálculos a mano tal y como se ha mostrado en el ejemplo anterior, se obtiene como resultado la matriz  $A$ , mientras que MATLAB devuelve la matriz  $B$  como resultado de `convn(X,  $G_u$ , 'valid')`. ¿Qué acaba de suceder? ¿Está mal codificada la función de MATLAB? ¿Está mal realizado el ejemplo?

$$A = \begin{pmatrix} 4 & 4 & 4 \\ -4 & -4 & -4 \\ -4 & -4 & -4 \end{pmatrix} \qquad B = \begin{pmatrix} -4 & -4 & -4 \\ 4 & 4 & 4 \\ 4 & 4 & 4 \end{pmatrix}$$

La respuesta a estas preguntas se podría resumir en que se ha realizado una “pequeña trampa” a la hora de calcular la convolución manualmente en el ejemplo, ya que no se ha aplicado correctamente la definición dada. ¿Qué sentido tiene hacer esto? En visión artificial y tratamiento de imágenes, muchos autores y librerías llaman convolución a la operación que se ha mostrado en el primer ejemplo, cuando en realidad no lo es y trae lugar a confusión. Dicha operación se llama correlación cruzada, denotada por  $(\star)$ , y que es muy similar a la convolución, pues su principal diferencia es que en la convolución “real”, el kernel se rota 180 grados antes de calcular la convolución “falsa” o correlación cruzada, es decir,  $X * Y = X \star (R_{180} \cdot Y)$ , donde  $R_{180}$  es la matriz de rotación de 180 grados. La correlación cruzada de dos imágenes (matrices) se define de la siguiente manera[4].

$$(f \star g)(u, v) = \sum_{i=-k}^k \sum_{j=-k}^k g(i, j) f(u + i, v + j)$$

Esta operación sí es con la que realmente se aplican los filtros a las imágenes y con la que se trabaja en general en el campo de la visión artificial. Es importante ver que ahora, al contrario que con la convolución,  $f \star g \neq g \star f$ . Algunas librerías de visión artificial tratan a la correlación cruzada como convolución debido al frecuente uso que tiene una sobre la otra y la forma similar que tienen de calcularse. Un ejemplo es OpenCV en la documentación de su función `filter2D`, donde se comenta que aplica una convolución cuando realmente aplica la correlación cruzada[6]. Finalmente, como se verá en próximos capítulos, las famosas redes neuronales convolucionales, no aplican convoluciones sino correlaciones cruzadas.



## Capítulo 3

# Aprendizaje automático

### 3.1. Perceptrón

Ya en el año 1958, el psicólogo Frank Rosenblatt propuso un modelo llamado perceptrón el cual estaba basado en el comportamiento y funcionamiento de las neuronas de un humano, y que podía aprender ponderando cada coeficiente de entrada a la neurona[7]. Hoy en día, tal y como se mostrará en esta sección, el perceptrón es la unidad fundamental de muchos modelos de *machine learning* y *deep learning*.

En este modelo se dispone de una serie de valores de entrada  $x_1, x_2, \dots, x_n$  y se quiere obtener una serie de valores de salida  $y_1, y_2, \dots, y_m$ . Esto se consigue mediante la ayuda de sus parámetros, que son una serie de pesos  $w_1, w_2, \dots, w_n$  y un sesgo o *bias*  $b$ ; y sus hiperparámetros, entre los que se encuentra una función  $f$  de activación.




Figura 3.1: Arquitectura de un perceptrón

En la Figura 3.1 se muestra la arquitectura del caso más simple de un perceptrón. Se tienen  $n$  entradas y una única salida. La primera parte del diagrama representa que tal y como decía Rosenblatt, cada valor de entrada debe multiplicarse por un cierto peso, de tal forma que si se representa esto en función de sus valores en un instante  $k$ , lo que se computa en el nodo  $n_1$  es la siguiente operación.

$$n_1(k) = b_1(k) + \sum_{i=1}^n x_i(k)w_i(k)$$

Una vez se ha realizado este cálculo, el valor pasa por una función de activación en el nodo  $a_1$ , pues esta arquitectura es común utilizarla para clasificar una entrada y es muy útil obtener una salida binaria donde se active únicamente la salida que represente la clase a la que pertenece la entrada dada. Aunque existen diferentes funciones de activación para las neuronas, al trabajar con un perceptrón, la función de activación por excelencia es la función escalón de Heaviside, donde  $u : \mathbb{R} \rightarrow \{0, 1\}$  y su expresión analítica es

$$u(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x \geq 0 \end{cases}.$$

Combinando ambas expresiones, se puede resumir en que la salida del perceptrón es equivalente a la siguiente ecuación:

$$y_1(k) = \begin{cases} 0 & \text{si } b_1(k) + \sum_{i=1}^n x_i(k)w_i(k) < 0 \\ 1 & \text{si } b_1(k) + \sum_{i=1}^n x_i(k)w_i(k) \geq 0 \end{cases}$$

Para dar un ejemplo claro de cómo funciona el perceptrón, se pueden tomar una serie de observaciones que tengan dos valores de entrada y uno de salida. Además, se supondrá que existen dos clases. Esto a fin de cuentas es asignar un valor de 0 o 1 a cada punto de  $\mathbb{R}^2$  tal y como se describe en la Figura 3.2.






Figura 3.2: Puntos etiquetados en  $\mathbb{R}^2$

Una solución rápida sería trazar una recta  $r : ax + by + c = 0$  que separe  $\mathbb{R}^2$  en dos regiones, de forma que todo punto que pertenezca a una región pertenece entonces a una misma clase, tal y como se observa en la Figura 3.3. Esta recta suele llamarse *decision boundary* o frontera de decisión. El problema entonces es hallar la recta  $r$ , pero se cumple que para este ejemplo es de la forma  $w_1x + w_2y + b = 0$ , siendo el problema encontrar los parámetros adecuados del modelo. La idea puede extrapolarse a diferentes dimensiones del problema, no solo 2 y 1 como se trata en este ejemplo. Las preguntas a resolver ahora son, ¿existen siempre dichos parámetros? ¿Cómo pueden hallarse? El propio Minsky se hizo estas preguntas en [8] y se dio cuenta de que dichos parámetros sí pueden hallarse en un número finito de pasos, siempre y cuando los puntos sean linealmente separables. Un ejemplo que no es linealmente separable es el de la función XOR tal y como se muestra en la Tabla 3.1 y Figura 3.4, pues no existe una recta  $r$  que separe  $\mathbb{R}^2$  en dos regiones de tal forma que cada región contenga puntos de una única clase, serían necesarias dos rectas para separar adecuadamente los puntos.

Figura 3.3: Puntos separados en  $\mathbb{R}^2$ Figura 3.4: Valores de  $x \oplus y$  en  $\mathbb{R}^2$ 

$x$	$y$	$x \oplus y$
0	0	0
0	1	1
1	0	1
1	1	0

Tabla 3.1: Función XOR

En cuanto a la pregunta de cómo hallar los parámetros, se consideran las siguientes ecuaciones, donde  $\mathbf{w}$  es el vector de pesos,  $t$  el valor esperado, y  $a$  la salida del perceptrón y se aplica el Algoritmo 3.1.1 para obtener los parámetros óptimos. En dicho algoritmo se supondrá que existe una matriz  $X$  de  $n$  filas que contiene los diferentes  $\mathbf{x}$ .

$$\mathbf{w}(k+1) = \mathbf{w}(k) + e(k)\mathbf{x}(k)$$

$$b(k+1) = b(k) + e(k)$$

$$e(k) = t(k) - a(k)$$

$$a(k) = u(\mathbf{w}^t(k)\mathbf{x}(k))$$

A cada una de las iteraciones que realiza el bucle exterior se les denomina épocas o *epoch*, que consiste en realizar el proceso de entrenamiento sobre todo el conjunto de datos. En este caso se está suponiendo que no va a recibir casos que no sean linealmente separables, pero de lo contrario se puede añadir un contador

**Algoritmo 3.1.1:** Regla de aprendizaje del perceptrón

---

**Datos:**  $X, t$   
**Resultado:**  $w, b$   
 $b \leftarrow 0$   
 $w \leftarrow \text{random}$   
 $k \leftarrow 0$   
**repetir**  
     $\text{acabar} \leftarrow \text{true}$   
    **para**  $i \leftarrow k$  **hasta**  $k + n - 1$  **hacer**  
         $e(i) \leftarrow t(i) - a(i)$   
         $w(i+1) \leftarrow w(i) + e(i)x(i) \text{ (mód } n)$   
         $b(i+1) \leftarrow b(i) + e(i)$   
         $\text{acabar} \leftarrow \text{acabar} \wedge e(i) == 0$   
    **fin**  
     $k \leftarrow k + n - 1$   
**mientras**  $\neg \text{acabar}$

---

$\text{max\_epochs}$  y fijar un número máximo para no caer en un bucle infinito. No sería tarea fácil determinar dicho valor, pues aunque el algoritmo converge en los casos previamente explicados, no en todos lo hace de manera rápida. A continuación se muestra cómo obtener la solución de la Figura 3.3.

$$X = \begin{pmatrix} 1 & -1 & 0 \\ 2 & 2 & -1 \end{pmatrix} \quad t = (1 \quad 0 \quad 0) \quad w = \begin{pmatrix} 1 \\ -0,8 \end{pmatrix}$$

1.
  - $a(1) = u\left((1 \quad -0,8) \begin{pmatrix} 1 \\ 2 \end{pmatrix}\right) = 0$
  - $e(1) = t(1) - a(1) = 1 - 0$
  - $w(2) = w(1) + e(1)x(1) = \begin{pmatrix} 1 \\ -0,8 \end{pmatrix} + \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1,2 \end{pmatrix}$





# Bibliografía

- [1] R. Szeliski, *Computer Vision: Algorithms and Applications, 2nd ed.* Springer International Publishing, 2022, ISBN: 978-3-030-34371-2. DOI: 10.1007/978-3-030-34372-9. dirección: <https://szeliski.org/Book/>.
- [2] López y H. I, “Método alternativo para calcular la convolución de señales en tiempo continuo,” 2009.
- [3] A. Lucía, “FFT: Transformada Rápida de Fourier,”
- [4] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016, págs. 326-330. dirección: <http://www.deeplearningbook.org>.
- [5] W. Gao, L. Yang, X. Zhang y H. Liu, “An improved Sobel edge detection,” *Proceedings - 2010 3rd IEEE International Conference on Computer Science and Information Technology, ICCSIT 2010*, vol. 5, págs. 67-71, 2010. DOI: 10.1109/ICCSIT.2010.5563693.
- [6] *OpenCV: Image Filtering*. dirección: [https://docs.opencv.org/4.x/d4/d86/group\\_\\_imgproc\\_\\_filter.html](https://docs.opencv.org/4.x/d4/d86/group__imgproc__filter.html).
- [7] A. Abeliuk y C. Gutiérrez, *Historia y evolución de la inteligencia artificial*.
- [8] M. Minsky y S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*. The MIT Press, ene. de 2017, ISBN: 9780262343930. DOI: 10.7551/MITPRESS/11301.001.0001.



Universidad de Alcalá  
Escuela Politécnica Superior



ESCUELA POLITECNICA  
SUPERIOR



Universidad  
de Alcalá